

한국어 뉴스 기사 데이터를 활용한 가짜 뉴스 판별 모델 개발

기계학습 텀프로젝트 Final Report

유윤서, 한원우

1. 문제 정의

이 프로젝트는 인공지능 기술을 활용하여 한국어 뉴스 기사의 진위 여부를 판별하는 것을 목표로 합니다. 소셜 미디어와 온라인 플랫폼의 발달로 정보의 생산과 유통 속도가 빨라지면서, 악의적인 의도를 가진 허위 정보가 사회 전반에 심각한 문제를 만들고 있습니다. 따라서 뉴스 기사의 제목과 본문 텍스트를 분석하여, 해당 기사가 사실에 기반한 '진짜 뉴스'인지, 허위로 조작된 '가짜 뉴스'인지 자동으로 분류하는 머신러닝 모델을 개발하고자 합니다.

2. 적용한 방법론 소개

성능 비교를 위해 고전적인 기계학습 방식과 최신 딥러닝 방식 두 가지를 시도했습니다.

가. 베이스라인 모델: TF-IDF + Logistic Regression

특징 추출: TfidfVectorizer 를 사용하여 뉴스 텍스트를 단어의 빈도를 반영한 수치 벡터로 변환했습니다.

분류기: 변환된 벡터를 입력으로 받아 Logistic Regression을 통해 분류 경계선을 학습했습니다.

한계: 단어의 등장 순서나 문맥을 무시하고, 단순히 특정 단어의 등장 여부와 빈도에만 의존한다는 단점이 있습니다.

나. 핵심 모델: KoBERT Fine-tuning

모델 선정: SKT가 개발한 KoBERT모델을 사용했습니다. 이는 대량의 한국어 말로 사전 학습되어 한국어의 복잡한 문법과 뉘앙스를 이해하는 데 특화된 모델입니다.

최대 길이를 64로 설정하고, 부족한 부분은 패딩 처리했습니다.

Attention Mask를 생성하여 모델이 패딩 토큰을 무시하고 실제 텍스트 정보에만

집중하도록 설계했습니다.

사전 학습된 BERT 모델의 출력층 위에 새로운 선형 분류기를 결합했습니다.

CrossEntropyLoss를 사용하여 모델의 예측 확률 분포와 실제 레이블 간의 오차를 계산했고 AdamW 를 사용하여 가중치 업데이트 시 과적합을 방지하고 안정적인 학습을 유도했습니다.

3. 최종 결과 및 해석 (Intermediate Results and Interpretation)

데이터셋: <https://dacon.io/competitions/official/235747/data> 위 링크에 나와있는 7가지 주제(사회, 정치, 스포츠 등)로 분류된 45,000개 이상의 뉴스 데이터를 활용함.

성능 비교 (정확도, Accuracy)는 아래 코랩을 통해 같은 데이터로 비교 분석해보았습니다.

https://colab.research.google.com/drive/18nprP0_xqGMRW55LT3igAJyKc8EOLOKd?usp=sharing

결과는 다음과 같이 나왔습니다.

```
print(f"🔍>> 베이스라인(TF-IDF) 정확도: {acc_ba
print("=====")

...

=== [1] 베이스라인 모델 학습 시작 ===

>> 베이스라인(TF-IDF) 정확도: 71.30%
=====
```

TF-IDF

```
spiece.model: 100%
... special_tokens_map.json: 100%
The tokenizer class you load from this d
The tokenizer class you load from this d
The class this function is called from
config.json: 100%
model.safetensors: 100%
Epoch 1/3
Training: 100%
Evaluating: 100%
Loss: 0.8303, Accuracy: 86.25%
Epoch 2/3
Training: 100%
Evaluating: 100%
Loss: 0.3620, Accuracy: 87.05%
Epoch 3/3
Training: 100%
Evaluating: 100%
Loss: 0.2392, Accuracy: 87.85%

>> KoBERT 최종 정확도: 87.85%
=====
```

KoBERT

결과 해석:

KoBERT 모델이 베이스라인 대비 약 16.5%p 높은 정확도를 기록했습니다. 이는 가짜 뉴스 판별에 있어 단순한 단어의 빈도보다 문맥을 이해하는 능력이 더 중요하다는 것을 알 수 있습니다. BERT의 양방향 어텐션 메커니즘이 기사의 앞뒤 문맥을 파악하여 진위를 판별하는 데 크게 기여했습니다.

87.85%의 정확도를 달성했으나, 여전히 약 12%의 오분류가 발생했습니다.

주로 사실에 기반했으나 제목이 극도로 자극적인 낚시성 기사와 고도의 풍자나 반어법이 사용된 사실을 모델이 가짜 혹은 진짜로 명확히 구분하는 데 어려움을 겪었습니다.

이런 결과가 나온 이유는 텍스트만으로는 파악하기 힘든 의도의 영역이 존재하기 때문으로 분석됩니다.

4. 결과 기반 향후 연구/개발 가능성 논의

가. 기술적 고도화

데이터 증강 및 모델 확장: 현재 사용한 KoBERT 모델보다 더 큰 파라미터를 가진 Ko-RoBERTa나 Ko-GPT 모델을 적용하거나, 역번역을 통해 학습 데이터를 증강하여 90% 이상의 정확도에 도전할 수 있습니다.

최근 가짜 뉴스는 텍스트뿐만 아니라 조작된 이미지를 동반하는 경우가 많습니다. 텍스트 분석 모델과 이미지 분석 모델을 결합한 멀티모달 모델로 확장한다면 판별 신뢰도를 획기적으로 높일 수 있습니다.

나. 설명 가능한 AI (XAI) 도입

단순히 이 기사는 가짜입니다 라고 결과만 알려주는 것을 넘어, 본문의 3번째 문장이 논리적으로 모순되기 때문에 가짜일 확률이 높습니다 라고 근거를 제시하는 기술이 필요합니다. LIME이나 SHAP 같은 XAI 알고리즘을 적용하여 모델의 판단 근거를 시각화하여 사용자의 신뢰를 얻을 수 있습니다.

다. 실제 서비스 적용

사용자가 인터넷 뉴스를 볼 때, 실시간으로 기사의 신뢰도를 신호등 색상으로 표시해 주는 플러그인이나 메신저나 SNS 상에서 의심스러운 기사 링크를 전송하면, 챗봇이 해당 기사의 진위 여부를 즉시 판별해 주는 서비스로 발전시킬 수 있습니다.

5. 결론

가짜뉴스 판별 프로젝트를 통해 최신 NLP 기술인 KoBERT가 가짜 뉴스 판별 문제 해결에 효과적임을 확인했습니다. 비록 100%의 완벽한 분류는 아니었으나, 텍스트의 문맥을 이해하는 AI가 정보 생태계의 건전성을 지키는 핵심 도구가 될 수 있다는 가능성을 발견한 점에 큰 의의가 있습니다.